Bitácora de desarrollo asistido de la Tarea 7 2

Jorge Josué Flores González · 6 de noviembre de 2026

Propósito. Completar los seis apartados de la consigna mediante una aplicación híbrida verificable, reutilizando el trabajo de la Tarea 7.1. La asistencia de Codex se utilizó para implementar, ejecutar pruebas, revisar textos y redactar documentación; los registros permiten contrastar los resultados.

Instrucción inicial. Se solicitó cumplir íntegramente la Tarea 7.2 y ahorrar créditos reutilizando el proyecto anterior. Al no encontrarse su carpeta local, se recuperó el repositorio publicado y se creó una copia y una rama independientes. Se conservaron los archivos de la 7.1 y una copia inalterada del verificador original.

Comparación. Se exigió una misma partición estratificada con semilla 42. El script comprobó la igualdad de los 200 índices de prueba y registró exactitudes, tiempos, 1.112 pesos y 25 sesgos. Se fijaron pandas 2.3.3 y scikit-learn 1.7.2 para mantener continuidad con el entorno anterior.

Generación real. Se instaló Qwen localmente y se procesaron las primeras 20 solicitudes reservadas, sin escogerlas según el resultado. Se conservaron textos completos y recortados. La ejecución guardó cada caso inmediatamente para permitir reanudación. No se sustituyeron las generaciones por ejemplos redactados ni se envió el CSV a una API generativa.

Correcciones y comprobación

Hallazgo y ajuste. La solicitud 3 negó el saldo negativo y fue aceptada originalmente. Se agregó contraste de cuenta y vivienda, además del tono entre 30 % y 60 %. La primera versión no reconocía «sin saldo negativo» ni «lo cual es alto»; se ajustaron esos patrones y se añadió una prueba del caso observado. Esta adaptación a la muestra se declara como limitación.

Pruebas. Se preservaron las cinco pruebas originales y las tres de la 7.1. Las pruebas nuevas comprueban contradicciones, tono intermedio, límites inclusivos y expresiones correctas con negación. El resultado final fue 19 passed. Dos pruebas comprueban explícitamente que la versión original acepta el texto que la regla nueva rechaza.

Medición. Se aplicaron ambas versiones a los mismos 20 textos: 7 rechazos antes y 14 después. La revisión asistida se registró caso por caso: un texto correcto, 19 problemáticos y cinco errores todavía aceptados después. No hubo rechazos del único texto correcto ni de seis controles correctos redactados por separado. Estas etiquetas no fueron validadas por un revisor independiente.

Límites documentados. Se encontraron confusiones entre edad y duración, causalidad inventada y afirmaciones de sostenibilidad financiera sin sustento. No se atribuyó al verificador cobertura semántica completa. La recomendación incluye validación externa, calibración, evaluación de subgrupos y revisión humana antes de cualquier uso bancario.

Trazabilidad. El repositorio conserva código, versiones de dependencias, revisión del modelo Qwen, hash del dataset, índices, generaciones, tabla por solicitud, anotaciones y salida de pytest. Los cambios se organizaron en commits de experimento, reglas, evidencia y documentación.

https://github.com/Jorgefloresraiz/Tarea_7_1/tree/codex/tarea-7-2