Aplicación híbrida de crédito con verificación

Jorge Josué Flores González

Atlantis University

MAI 540 Machine Learning

Kevin A. García Gallardo

7 de noviembre de 2026

Comparación predictiva y protocolo

La aplicación combina un predictor de crédito, Qwen y un verificador. Las reglas nuevas elevaron los rechazos de 7 a 14 entre 20 explicaciones, pero persistieron errores aceptados. El experimento demuestra controles concretos, no que el sistema esté preparado para decidir créditos o informar a clientes sin supervisión.

German Credit se dividió en 800 solicitudes de entrenamiento y 200 de prueba, con test_size=0.20, stratify=y y random_state=42. Se comprobó la igualdad de índices para ambos modelos. La codificación y el escalado de la red se ajustaron solo con entrenamiento; los índices y el hash del CSV quedaron registrados.

La red tiene 61 entradas transformadas, capas ocultas de 16 y 8 neuronas ReLU y una salida logística. Sus matrices contienen 976 + 128 + 8 = 1.112 pesos; los 25 sesgos elevan el total a 1.137 parámetros. Aprende relaciones no lineales mediante ajuste de pesos (scikit-learn developers, s. f.). Random Forest combina 200 árboles que aprenden particiones de los atributos.

Tabla 1

Comparación sobre las mismas 200 solicitudes

Modelo	Aciertos	Exactitud	Ajuste
Random Forest	150/200	75,0 %	0,170 s
Red neuronal	147/200	73,5 %	0,447 s

Elegiría Random Forest como candidato: obtuvo tres aciertos más y menor tiempo en esta ejecución. La diferencia no prueba superioridad general; hace falta validar detección de créditos malos y calibración. Los tiempos corresponden a una sola medición local.

Explicaciones y reglas de verificación

Se procesaron las primeras 20 solicitudes de prueba con Qwen2.5-0.5B-Instruct, localmente en CPU, sin muestreo y con máximo de 70 tokens nuevos (Qwen, s. f.). Se conservaron el texto bruto, el recorte a oraciones completas y la probabilidad. Ambos verificadores evaluaron exactamente el mismo texto recortado.

El caso 1 (25,5 %) fue rechazado por tono: «El modelo de riesgo de crédito sugiere una probabilidad de crédito malo del 26%, lo cual es alto para una persona con una edad de 36 años y una duración de 18 meses». El caso 19 (12 %) también fue rechazado: «El modelo de riesgo de crédito sugiere una probabilidad de crédito malo del 12%, ya que la suma de las probabilidades de crédito bueno y malo es de 76% en este caso». El 76 no procede de sus datos ni del predictor.

El caso 3 (56,5 %) pasó el control original: «El modelo de riesgo de crédito sugiere una probabilidad de crédito malo del 56%, lo cual es alto para una persona con una edad de 48 años y una duración de 24 meses en una cuenta corriente sin saldo negativo». Sin embargo, el registro indica saldo negativo, edad 48, plazo 24, monto 1.024 y vivienda propia. La negación del saldo es falsa; el tono también contradice la franja intermedia.

La primera regla contrasta expresiones de cuenta y vivienda con los datos, incluida la negación del saldo registrado. La segunda detecta tono extremo entre 30 % y 60 %, inclusive. Las pruebas reproducen textos aceptados por la versión original y rechazados por la nueva. Pasaron 19 pruebas, incluidas las cinco originales, los límites de la franja y controles de negaciones.

Efecto observado y límites

Tabla 2

Verificación de las mismas 20 explicaciones

Indicador	Antes	Después
Explicaciones rechazadas	7 (35 %)	14 (70 %)
Explicaciones aceptadas	13	6
Errores aceptados según revisión	12	5
Textos correctos rechazados	0/1	0/1

La revisión semántica asistida identificó 19 textos problemáticos y uno correcto; cada juicio se conserva con su justificación. No hubo falsos positivos en ese único texto correcto ni en seis controles redactados con afirmaciones válidas. Esta evidencia es limitada y no sustituye una revisión humana independiente. Los controles se distinguen de las generaciones reales. La comparación por solicitud está en rechazos.csv.

Persisten errores importantes: el caso 13 usa los cuatro meses del préstamo como edad y pasa porque el número existe entre los datos. El caso 6 afirma sostenibilidad financiera sin demostrarla. En el caso 4, «persona sola» no está sustentado; se rechaza por tono, no por detectar esa invención. Las reglas tampoco cubren todas las paráfrasis, negaciones o atribuciones causales. El recorte puede ocultar errores del final del texto bruto.

Las franjas son convenciones didácticas y las reglas se refinaron con esta muestra; los resultados no estiman generalización. Antes de uso bancario recomendaría calibración, evaluación por subgrupos, revisión humana, pruebas con un corpus independiente y trazabilidad de cada afirmación a su campo. El texto rechazado se sustituye por un respaldo determinista. El componente generativo no debe presentarse como explicación causal del predictor.

Referencias

Atlantis University. (2026). *Tarea 7.2 Aplicación híbrida con verificación* [Consigna de curso].

Qwen. (s. f.). *Qwen2.5-0.5B-Instruct* [Modelo de lenguaje]. Hugging Face. https://huggingface.co/Qwen/Qwen2.5-0.5B-Instruct

scikit-learn developers. (s. f.). *Neural network models (supervised)*. https://scikit-learn.org/stable/modules/neural_networks_supervised.html

Repositorio del proyecto: https://github.com/Jorgefloresraiz/Tarea_7_1/tree/codex/tarea-7-2